



گزارش تمرین اول _ مقدمه علم داده

تحلیل دیتاست

اعضای گروه:

مریم دار ۴۰۲۳۶۲۳۰۱۴

استاد درس : استاد تابع الحجّه

فهرست مطالب

۳	تحلیل دیتاست فیلم های برتر IMDB
۳	۱. ابعاد دیتاست
۳	۲. توصیف دیتاست
۴	۳. آمار دقیق ستون ها
۵	۴. آشنایی با نمونه ی داده ها
۶	۵. توصیف آماری دیتاست

تحلیل دیتاست فیلم های برتر IMDB :

در ادامه به تحلیل داده های ۱۰۰۰ فیلم برتر IMDB با استفاده از کتابخانه pandas می پردازیم .

بررسی ابعاد، ویژگی ها، مقادیر گمشده، انواع نوع داده و توصیفات آماری در مجموعه داده ی مورد نظر در این گزارش انجام شده است .

- منبع دیتاست : ۱۰۰۰ فیلم برتر IMDB

۱. ابعاد دیتاست :

- ابعاد دیتاست : شامل ۱۶ ستون (ویژگی) و ۱۰۰۰ سطر (فیلم) است.
- ستون ها (Features) :

```
DATASET DIMENSIONS

Dataset Shape:
1000 rows (movies) x 16 columns(features)

features :
Index(['Poster_Link', 'Series_Title', 'Released_Year', 'Certificate',
       'Runtime', 'Genre', 'IMDB_Rating', 'Overview', 'Meta_score', 'Director',
       'Star1', 'Star2', 'Star3', 'Star4', 'No_of_Votes', 'Gross'],
      dtype='object')
```

ابعاد دیتاست و نام ستون ها

۲. توصیف دیتاست :

با نگاهی به اطلاعات دیتا فریم می بینیم که ۲ ستون با نوع داده ی float یک ستون int و ۱۳ ستون object وجود دارد . با بررسی نام ستون ها مشخص است که برخی دیگر از ستون ها هم باید به دیتا پیپی عددی تبدیل شوند.

همچنین تعداد عناصر غیر null هر ستون را مشاهده می کنیم که نشان از وجود مقدار null در برخی ستون ها می دهد که باید حتما به آنها بپردازیم .

```
# Column Non-Null Count Dtype
---
0 Poster_Link 1000 non-null object
1 Series_Title 1000 non-null object
2 Released_Year 1000 non-null object
3 Certificate 899 non-null object
4 Runtime 1000 non-null object
5 Genre 1000 non-null object
6 IMDB_Rating 1000 non-null float64
7 Overview 1000 non-null object
8 Meta_score 843 non-null float64
9 Director 1000 non-null object
10 Star1 1000 non-null object
11 Star2 1000 non-null object
12 Star3 1000 non-null object
13 Star4 1000 non-null object
14 No_of_Votes 1000 non-null int64
15 Gross 831 non-null object
dtypes: float64(2), int64(1), object(13)
```

نوع داده ی هر ستون و تعداد مقادیر غیر null

۳. آمار دقیق ستون ها :

در این بخش با ستون های دیتاست بیشتر آشنا می شویم .

نام , نوع داده , تعداد مقادیر یکتا و مقادیر گمشده اگر داشته باشند .

• ستون ها (Features):

۱. **Poster_Link**: آدرس پوستر هر فیلم (رشته)
۲. **Series_Title**: عنوان فیلم (رشته)
۳. **Released_Year**: سال انتشار فیلم (رشته)
۴. **Certificate**: رتبه سنی مجاز فیلم (رشته)
۵. **Runtime**: مدت زمان فیلم به دقیقه (رشته)
۶. **Genre**: لیستی از ژانرهای مرتبط با فیلم (لیستی از رشته ها)
۷. **Imdb_Rating**: امتیاز IMDB فیلم. (عدد اعشاری)
۸. **Overview**: خلاصه ای از فیلم (رشته)
۹. **Meta_Score**: میانگین امتیاز منتقدان حرفه ای (عدد اعشاری)
۱۰. **Director**: نام کارگردان فیلم (رشته)
۱۱. **Top 4 Stars**: چهار ستاره ی اصلی هر فیلم (رشته)
۱۲. **No_of_Votes**: تعداد رای های کاربران در IMDB برای هر فیلم (عدد صحیح)
۱۳. **Gross**: مجموع فروش بلیط در سینما (درآمد) به دلار USD (رشته)

ستون های *Certificate, Meta_score, Gross* به ترتیب ۱۶.۹٪, ۱۵.۷٪, ۱۰.۱٪ مقدار گمشده دارند که باید در آینده آنها را کنترل کنیم .

برخی ستون ها که مقادیر یکتای به نسبت زیادی دارند اطلاعات زیادی به ما دربارهی این لیست از فیلم ها می دهند:

- این ۱۰۰۰ فیلم در ۱۰۰ سال متمایز منتشر شده اند .
- کلاً ۱۷ مقدار امتیاز مختلف به این ۱۰۰۰ فیلم داده شده است و باقی امتیاز ها تکراری هستند .
- تقریباً ۵۰۰ کارگردان مختلف در این لیست نام برده شده اند .

```

Column Name: Runtime
Data Type: object
Unique Values Count: 140
Missing Values: 0 (0.00%)

Column Name: Genre
Data Type: object
Unique Values Count: 202
Missing Values: 0 (0.00%)

Column Name: IMDB Rating
Data Type: float64
Unique Values Count: 17
Missing Values: 0 (0.00%)

Column Name: Overview
Data Type: object
Unique Values Count: 1000
Missing Values: 0 (0.00%)

Column Name: Meta_score
Data Type: float64
Unique Values Count: 63
Missing Values: 157 (15.70%)

Column Name: Director
Data Type: object
Unique Values Count: 548
Missing Values: 0 (0.00%)

```

نمونه ای از آمار جزئی ستون ها

۴. آشنایی با نمونه‌ی داده‌ها :

در تصویر زیر پنج فیلم اول و آخر دیتاست را با تمام ویژگی‌ها مشاهده می‌کنیم .

df.head()

✓ 0.0s

	Poster_Link	Series_Title	Released_Year	Certificate	Runtime	Genre	IMDB_Rating	Overview	Meta_score	Director	Star1	Star2	Star3	Star4	No_of_Votes	Gross
0	https://m.media-amazon.com/images/M/MV5BMDFKYT...	The Shawshank Redemption	1994	A	142 min	Drama	9.3	Two imprisoned men bond over a number of years...	80.0	Frank Darabont	Tim Robbins	Morgan Freeman	Bob Gunton	William Sadler	2343110	28,341,469
1	https://m.media-amazon.com/images/M/MV5BM2MyNj...	The Godfather	1972	A	175 min	Crime, Drama	9.2	An organized crime dynasty's aging patriarch t...	100.0	Francis Ford Coppola	Marlon Brando	Al Pacino	James Caan	Diane Keaton	1620367	134,966,411
2	https://m.media-amazon.com/images/M/MV5BMTMxNT...	The Dark Knight	2008	UA	152 min	Action, Crime, Drama	9.0	When the menace known as the Joker wreaks havoc...	84.0	Christopher Nolan	Christian Bale	Heath Ledger	Aaron Eckhart	Michael Caine	2303232	534,858,444
3	https://m.media-amazon.com/images/M/MV5BMWVmMwMG...	The Godfather: Part II	1974	A	202 min	Crime, Drama	9.0	The early life and career of Vito Corleone in ...	90.0	Francis Ford Coppola	Al Pacino	Robert De Niro	Robert Duvall	Diane Keaton	1129952	57,300,000
4	https://m.media-amazon.com/images/M/MV5BMWU4N2...	12 Angry Men	1957	U	96 min	Crime, Drama	9.0	A jury holdout attempts to prevent a miscarria...	96.0	Sidney Lumet	Henry Fonda	Lee J. Cobb	Martin Balsam	John Fiedler	689845	4,360,000

df.tail()

✓ 0.0s

	Poster_Link	Series_Title	Released_Year	Certificate	Runtime	Genre	IMDB_Rating	Overview	Meta_score	Director	Star1	Star2	Star3	Star4	No_of_Votes	Gross
995	https://m.media-amazon.com/images/M/MV5BNCEwMT...	Breakfast at Tiffany's	1961	A	115 min	Comedy, Drama, Romance	7.6	A young New York socialite becomes interested ...	76.0	Blake Edwards	Audrey Hepburn	George Peppard	Patricia Neal	Buddy Ebsen	166544	NaN
996	https://m.media-amazon.com/images/M/MV5BODk3Yj...	Giant	1956	G	201 min	Drama, Western	7.6	Sprawling epic covering the life of a Texas ca...	84.0	George Stevens	Elizabeth Taylor	Rock Hudson	James Dean	Carroll Baker	34075	NaN
997	https://m.media-amazon.com/images/M/MV5BM2U3Yz...	From Here to Eternity	1953	Passed	118 min	Drama, Romance, War	7.6	In Hawaii in 1941, a private is cruelly punish...	85.0	Fred Zinnemann	Burt Lancaster	Montgomery Clift	Deborah Kerr	Donna Reed	43374	30,500,000
998	https://m.media-amazon.com/images/M/MV5BZTBmMj...	Lifeboat	1944	NaN	97 min	Drama, War	7.6	Several survivors of a torpedoed merchant ship...	78.0	Alfred Hitchcock	Tallulah Bankhead	John Hodiak	Walter Slezak	William Bendix	26471	NaN
999	https://m.media-amazon.com/images/M/MV5BMTY5OD...	The 39 Steps	1935	NaN	86 min	Crime, Mystery, Thriller	7.6	A man in London tries to help a counter-espion...	93.0	Alfred Hitchcock	Robert Donat	Madeleine Carroll	Lucie Mannheim	Godfrey Tearle	51853	NaN

Python

نمونه داده‌ها

۵. توصیف آماری دیتاست :

در این قسمت توصیفات آماری ای درباره‌ی ستون‌های دیتاست خواهیم داشت .

ستون های *Released_year, Runtime, Gross* که در ابتدا دیتاتایپ آنها *object* بود به *int* و *float* تبدیل شده اند.

```
Poster_Link      object
Series_Title     object
Released_Year    Int64
Certificate      object
Runtime          int64
Genre            object
IMDB_Rating      float64
Overview         object
Meta_score       float64
Director         object
Star1            object
Star2            object
Star3            object
Star4            object
No_of_Votes      int64
Gross            float64
dtype: object
```

با بررسی ای کلی متوجه می‌شویم که میانگین امتیاز در میان این فیلم ها ۷.۹ ، کمترین امتیاز ۷.۶ و بیشترین ۹.۳ بوده است.

بررسی ستون سال انتشار نشان می‌دهد که فیلم هایی از سال ۱۹۲۰ تا ۲۰۲۰ در این دیتاست جای گرفته اند .

	Released_Year	Runtime	IMDB_Rating	Meta_score	No_of_Votes	Gross
count	999.0	1000.000000	1000.000000	843.000000	1.000000e+03	8.310000e+02
mean	1991.217217	122.891000	7.949300	77.971530	2.736929e+05	6.803475e+07
std	23.297025	28.093671	0.275491	12.376099	3.273727e+05	1.097500e+08
min	1920.0	45.000000	7.600000	28.000000	2.508800e+04	1.305000e+03
25%	1976.0	103.000000	7.700000	70.000000	5.552625e+04	3.253559e+06
50%	1999.0	119.000000	7.900000	79.000000	1.385485e+05	2.353089e+07
75%	2009.0	137.000000	8.100000	87.000000	3.741612e+05	8.075089e+07
max	2020.0	321.000000	9.300000	100.000000	2.343110e+06	9.366622e+08

توصیف ویژگی های آماری مختلف برای هر ستون