



گزارش تمرین دوم _ مقدمه‌ی علم داده

تحلیل توصیفی دیتاست

اعضای گروه:

مریم دار ۴۰۲۳۶۲۳۰۱۴

استاد درس : استاد تابع الحجّه

فهرست مطالب

۳	تحلیل توصیفی دیتاست فیلم های برتر IMDB:.....
۳	۱. توضیح دیتاست :.....
۴	۲. یافته های توصیفی :.....
۵	۳. مقادیر پرت :.....
۶	۴. مصور سازی و تفسیر آنها :.....
۶	۴.۱. نمودار هیستوگرام:.....
۸	۴.۲ نمودار جعبه ای :
۹	۴.۳. نمودار پراکندگی:.....
۱۰	۴.۴. نمودار میله ای:.....
۱۲	۵. نتیجه گیری اولیه درباره ی الگوهای داده :.....

تحلیل توصیفی دیتاست فیلم های برتر IMDB :

در ادامه به تحلیل توصیفی دیتاست ۱۰۰۰ فیلم برتر IMDB می پردازیم .

بررسی ابعاد, نام ستون ها, نوع داده ها ,مقادیرگمشده, انواع آماره ها برای متغیر های عددی و طبقه بندی , شناسایی و تحلیل داده های پرت و مصور سازی های متنوع برای انواع روابط بین ویژگی ها در مجموعه داده ی مورد نظر در این گزارش انجام شده است .

- منبع دیتاست : ۱۰۰۰ فیلم برتر IMDB

۱. توضیح دیتاست :

- ابعاد دیتاست : شامل ۱۶ ستون (ویژگی) و ۱۰۰۰ سطر (فیلم) است.
- ستون ها (Features) :

DATASET DIMENSIONS

Dataset Shape:

1000 rows (movies) x 16 columns(features)

features :

```
Index(['Poster_Link', 'Series_Title', 'Released_Year', 'Certificate',  
      'Runtime', 'Genre', 'IMDB_Rating', 'Overview', 'Meta_score', 'Director',  
      'Star1', 'Star2', 'Star3', 'Star4', 'No_of_Votes', 'Gross'],  
      dtype='object')
```

ابعاد دیتاست و نام ستون ها

- ستون ها (Features):

۱. **Poster_Link**: آدرس پوستر هر فیلم (رشته)
۲. **Series_Title**: عنوان فیلم (رشته)
۳. **Released_Year**: سال انتشار فیلم (رشته)
۴. **Certificate**: رتبه سنی مجاز فیلم (رشته)
۵. **Runtime**: مدت زمان فیلم به دقیقه (رشته)
۶. **Genre**: لیستی از ژانرهای مرتبط با فیلم (لیستی از رشته ها)
۷. **Imdb_Rating**: امتیاز IMDB فیلم (عدد اعشاری)
۸. **Overview**: خلاصه ای از فیلم (رشته)
۹. **Meta_Score**: میانگین امتیاز منتقدان حرفه ای (عدد اعشاری)
۱۰. **Director**: نام کارگردان فیلم (رشته)
۱۱. **Top 4 Stars**: چهار ستاره ی اصلی هر فیلم (رشته)
۱۲. **No_of_Votes**: تعداد رای های کاربران در IMDB برای هر فیلم (عدد صحیح)

۱۳. **Gross** : مجموع فروش بلیط در سینما (درآمد) به دلار USD (رشته)

ستون های *Certificate, Meta_score, Gross* به ترتیب ۱۶.۹٪, ۱۵.۷٪, ۱۰.۱٪ مقدار گمشده دارند که باید در آینده آنها را کنترل کنیم .

Poster_Link	0
Series_Title	0
Released_Year	0
Certificate	101
Runtime	0
Genre	0
IMDB_Rating	0
Overview	0
Meta_score	157
Director	0
Star1	0
Star2	0
Star3	0
Star4	0
No_of_Votes	0
Gross	169
dtype: int64	

تعداد مقادیر گمشده هر ستون

۲. یافته‌های توصیفی :

با بررسی میانگین و میانه‌های ستون های عددی مختلف به مقارن بودن یا نبودن توزیع داده‌ها پی میبریم . در این میان ستون های Gross و No_of_votes بیشترین اختلاف میانگین و میانه را دارند و همانطور که در نمودار های توزیع آنها هم میبینیم بسیار چوله دار و نامتقارن هستند . همچنین این آماره ها نشان می دهند که فیلم های انتخاب شده عموماً دارای امتیاز های بالا از ۷.۶ تا ۹.۳ و با پراکندگی کم هستند . محبوب ترین ژانر این لیست درام بوده است و این فیلم ها در سال های ۱۹۲۰ تا ۲۰۲۰ منتشر شده اند و سالی که بیشترین فیلم را دارد ۲۰۱۴ بوده است .

۳. مقادیر پرت :

با بررسی و پیدا کردن داده های پرت به این تعداد و ویژگی ها برخورد کردیم .

اما با بررسی نمودار جعبه ای آنها و همچنین بازه کمترین و بیشترین مقادیر آنها و ماهیت آن ویژگی ها بهتر دیده شد که این مقادیر پرت دیتای واقعی هستند و خطا یا ارور نیستند که حذف شوند .

مقدار فروش با اینکه مقدار پرت زیادی داشت اما یکی از مهم ترین اطلاعات را به ما می دهد که برخی فیلم ها هستند که با تفاوت بسیار زیادی در فروش موفق تر بوده و بررسی آنها میتواند بسیار کمک کننده باشد . و مقدار منفی یا صفر یا خیلی زیاد که غیر منطقی باشد در آن بازه نیست .

یا مثلا مدت زمان یک فیلم همانطور که میبینیم بعضی فیلم ها زمان کوتاه تر یا برخی خیلی طولانی داشتند که اندک هم بودند و بیشتر مدت زمان ها در یک بازه هستند و نمودار توزیع آن هم متقارن است . اما با دیدن اینکه این زمان های پرت منطقی هستند و صفر با مثلا ۱۰ ساعت نیست . مشخص میشود که این داده های پرت هم اطلاعات میدهند و خطا نیستند.

حتی امتیاز IMDB کاملا مشخص است که تعداد اندکی فیلم هست که امتیاز بالای ۹ میگیرد و خودبه خود داده پرت محسوب میشود اما جرو مهم ترین اطلاعاتی هستند که داریم . یا مثلا تعداد رای ها، برخی فیلم ها بسیار معروف شده و میلیونی رای دارند اما برخی انقدر معروف نشده اند و تعداد رای کمتری دارند .

در کل بعد از دیدن تعداد مقادیر پرت با بررسی ماهیت آنها و در قدم بعدی بررسی اینکه مقادیر داده ها در بازه غیر منطقی ای نیستند ما را به این تصمیم می رساند که نباید هیچکدام را حذف کنیم . و باید همین گونه که هستند بی تغییر نگه داریم.

در آینده بسته به مدلی که قرار است با آن کار کنیم میتوانیم این مقادیر را *rescale* کنیم اگر که در محاسبات مشکل ایجاد کند.

```
Outliers in Released_Year: 7
Outliers in Runtime: 29
Outliers in IMDB_Rating: 13
Outliers in Meta_score: 7
Outliers in No_of_Votes: 67
Outliers in Gross: 89
```


تعداد مقادیر پرت ستون های عددی

۴. مصور سازی و تفسیر آنها :

۴.۱. نمودار هیستوگرام:

نمودار های توزیع احتمال و توزیع تجمعی ستون های عددی مختلف را مشاهده می کنیم .


۱. سال انتشار : هر چه سال انتشار به حال نزدیک تر میشود و جلو رفته است تعداد فیلم های موجود در این لیست هم بیشتر شده و سال به سال سینما از این لحاظ موفق تر شده است .
۲. مدت زمان پخش : همانطور که میبینیم نمودار به نسبت متقارنی دارد و کاملاً منطقی است که اکثر فیلم ها در بازه زمانی ۱۰۰ تا ۱۵۰ دقیقه هستند و فیلم های خاص با زمان های بیشتر یا کمتر تعداد کمتری دارند .
۳. امتیاز IMDB : مشاهده میشود که تعداد فیلم های با امتیاز بالای ۸.۵ شروع به کم شدن میکنند و فیلم های با امتیاز بالای ۹ بسیار اندک است در این مقیاس . و اکثر فیلم های امتیاز بین ۷.۵ تا ۸.۵ در این لیست دارند .
۴. امتیاز منتقدان : میانگین امتیاز منتقدان بسیار خوب به نظر می رسد اکثر امتیاز ها امتیاز های نسبتاً بالا و خوبی هستند (بین ۷۰ تا ۹۰) و برخی فیلم ها با انتقاد های بد و امتیاز های کم روبرو شده اند و تعداد آنها کمتر است همچنین تعداد به نسبت کمتری امتیاز کامل و بالا ۹۰ گرفته اند همانطور که از این لیست برمی آید.
۵. تعداد رای های کاربران : از آنجایی که در نتیجه نهایی امتیاز IMDB تعداد رای کاربران به علاوه رای آنها با هم دخیل هستند و فیلمی که فقط یک نفر به آن ۱۰ داده باشد در این لیست بالا نمی آید . منطقی است که در این ۱۰۰۰ فیلم برتری که داریم اکثر فیلم ها دارای تعداد رای بالا باشند . (همانطور که میبینیم واحد تعداد رای ها به میلیون است) اما همانطور که میبینیم بسیار این نمودار چوله دار و به چپ است و اختلاف میانه با کمترین مقدار و بیشترین مقدار تفاوت بسیار زیادی دارد و واریانس بالایی را مشاهده میکنیم . اکثریت فیلم ها (حدود ۹۰ تا ۹۵ درصد آنها) مقدار رای به نسبت کمتری دارند و اندکی از فیلم ها هستند که تعداد رای آنها بسیار زیاد شده است . این فیلم ها آن دسته ای هستند که بسیار معروف شده و افراد زیادی از سراسر جهان به آنها رای داده اند . و به نسبت کل فیلم ها تعداد اندکی با این اتفاق روبرو میشوند . و این اختلاف زیادی که مشاهده میشود به این دلیل است که ما فقط ۱۰۰۰ فیلم را مشاهده میکنیم و این اختلاف با شدت بیشتری دیده میشود .
۶. مقدار فروش : مانند ستون قبل این ویژگی هم مقادیر بالای آن بسیار نادر است و اکثریت فیلم های توی این لیست یک مقدار مشابه فروش داشته اند و تعداد اندکی هستند که فروش بسیار بیشتری داشته اند .



۴.۲ نمودار جعبه‌ای :

با بررسی نمودار جعبه ای بسیار آشکار میتوان مقادیر پرت را مشاهده کرد . همانطور که میبینیم در دیتایی که در دست داریم مقادیر پرت بسیاری مشاهده میشود اما بررسی هر کدام نشان میدهد که این دیتا ها خطا نیستند و هر کدام دیتای واقعی ای است که اطلاعات زیادی به ما دهد.

۱. سال انتشار : برخی فیلم های کلاسیک در این لیست قرار گرفته است که سال انتشار آنها خیلی پرت از باقی فیلم ها است و این نشان دهنده ی محبوب بودن آن فیلم ها بعد از این همه گذر زمان است .
۲. مدت زمان پخش : داده های پرت اینجا فیلم های اندکی هستند که زمان پخش آنها از حالت معمول بیشتر است اما همچنان معقول هستند .
۳. امتیاز IMDB : همانطور که گفته شد قبلا فقط تعداد کمی فیلم هست که امتیاز آنها بالا ۸.۷۵ باشد و باقی همگی در یک بازه نزدیک به هم قرار میگیرند .
۴. میانگین امتیاز منتقدان : داده های پرت در این جا نشان دهنده برخی اندکی از فیلم ها است که بازخورد کمتری از سمت منتقدان دریافت کرده است .
۵. تعداد رای کاربران : داده های پرت این قسمت به نسبت بیشتر هستند و در سمت چپ حتی متراکم تر هستند . این نشان میدهد جدای از اکثر فیلم ها که تعداد رای آنها نزدیک به هم بوده برای آن مقدار اندکی که تعداد رای بیشتری داشته اند هم هر چقدر تعداد رای بیشتر میشود تعداد فیلم ها کمتر میشوند و داده ها دورتر از هم قرار میگیرند .
۶. مقدار فروش : مانند ویژگی قبلی داده های پرت این قسمت هم به نسبت بالاست و با بیشتر شدن مقدار فروش این تعداد داده های پرت حتی کمتر و کمتر میشود .




۴.۳. نمودار پراکندگی:

نمودار های پراکندگی بین ویژگی های عددی و ستون IMDB_Rating را مشاهده میکنیم .


مقدار فروش و امتیاز IMDB رابطه مستقیمی با هم ندارند و نمیتوان مثلاً پیش بینی کرد که امتیاز بالاتر فروش بالاتر هم دارد

با بیشتر شدن تعداد رای ها امتیاز IMDB هم بیشتر شده است و این نشان دهنده ی تاثیر تعداد رای علاوه بر محتوای رای هم ها در نتیجه نهایی نمره IMDB است .

اما باقی نمودار به این صورت اطلاعات زیادی به ما نمیدهند و خوب است برای فهمیدن رابطه بین ستون ها برخی را نرمال و یا فقط میانگین یا مینیمم و ماکسیمم یک ستون با دیگری به صورت نمودار خطی مقایسه شود .



از دیگر نمودار های پراکندگی ای که اطلاعات خوبی به ما میدادند نمودار های زیر هستند .




- نمودار سمت چپ رابطه بین مقدار فروش و سال انتشار را بیان می‌کند که نشان می‌دهد در ۲۰ سال گذشته مقدار فروش هم بیشتر شده است و مقادیر فروشی که بسیار بالا بوده اند در همین سال های اخیر رخ داده است .
 - نمودار سمت راست دیتای جالبی را انتقال میدهد . فیلم هایی که هم توسط جمعیت زیادی از مردم محبوب واقع شده اند و هم از نظر منتقدان امتیاز بالایی گرفته اند در بالا راست این نمودار قرار گرفته و تعداد اندکی را مشاهده میکنیم . کمتر فیلمی بوده هم مورد محبت مردم قرار گرفته و هم امتیاز بالایی از منتقدان درافت کرده .
- تعداد زیادی از فیلم ها را در بالا سمت چپ مشاهده میکنیم که نشان میدهد فیلم هایی بوده اند که بسیار مورد تقدیر منتقدان قرار گرفته اند و جنبه های هنری سینمایی و ... بالایی داشته اند و امتیاز بالایی از منتقدان کسب کرده اند اما آنچنان در دل عامه مردم محبوب و معروف نشده و افراد کمتری به نسبت آنها را میشناسند و تعداد رای های کمتری دارند .
- عده ای هم هستند که تقریبا به مقدار زیادی بین مردم معروف شده و رای های بسیاری داشته اند اما بین منتقدان آنقدر امتیاز خوبی نگرفته اند که این دسته در وسط نمودار نمایان است .

۴.۴. نمودار میله ای:


برای ویژگی های طبقه بندی از نمودار های ستونی استفاده کرده ایم .

این نمودار ها فراوانی و مقادیر برتر هر ستون را بر اساس مقدار فراوانی آن در لیست نشان می‌دهد.

۱. رتبه سنی مجاز فیلم : میبینیم که در این لیست از فیلم ها رتبه های U, A, UA, R به ترتیب بیشترین تکرار را داشته اند. که به ترتیب مربوط به همه سنین , کودکان , نوجوانان , بزرگسالان می باشند .
۲. ژانر: فیلم هایی با ژانر درام و عاشقانه و کمدی بسیار پرتکرار بوده اند .
۳. کارگردان هایی که بیشترین فیلم را در این لیست داشته اند مشاهده میکنیم . که همگی کارگردان های سرشناس و محبوبی هستند.
۴. بازیگر هایی که فیلم های زیادی شان در این لیست وجود داشته و نامشان زیاد تکرار شده را مشاهده میکنیم که نام اکثریت آنها آشنا و به گوشمان خورده است حتی اگر فیلمشان را ندیده باشیم .



برای ویژگی های طبقه بندی نمودار جعبه ای رسم کردیم و همانطور که مشاهده می شود در certificate مقدار پرت به چشم می خورد که به این دلیل است که برخی رتبه های سنی مجاز فیلم کمتری در این لیست دارند اما کاملاً داده ای واقعی است و خطا نمی باشد پس باید آنها را هم بدون تغییر نگه داریم .



۵. نتیجه گیری اولیه درباره‌ی الگوهای داده :

در این داده ها فیلم هایی با امتیاز بالا و پراکندگی بسیار کم مشاهده میکنیم که به دلیل دیتاستی است که انتخاب کردیم و در آن فقط ۱۰۰۰ فیلم برتر IMDB را داریم پس منطقی است که امتیازات این گونه باشد .

مشاهده کارگردان و ستاره های محبوب به همراه ژانر های محبوب کاربران (درام-عاشقانه-کمدی) در صدر لیست فراوانی ها به عنوان علائمی از علایق عمومی هستند.

عدم وجود رابطه مستقیم امتیاز IMDB و مقدار فروش نشان می دهد که محبوبیت فنی و امتیاز ها به تنهایی پیش بینی کننده ی موفقیت تجاری نیست و چه بسا فیلم هایی که امتیاز کم داشته اند اما موفقیت تجاری آنها غیر قابل مقایسه است .

روند کلی افزایش فروش در دو دهه اخیر نشان دهنده ی رشد بازار فیلم در سال های جدید است . همچنین تفاوت نظر کاربران و منتقدان نشان از این می دهد که فیلمی که معروف است حتما دارای ارزش های سینما نیست و فیلم هایی که برای ارزش های سینما و معیار های منتقدان قابل قبول باشد حتما باعث نمی شود بین مردم هم معروف شود.